

D I E G O A N T O N I O Z Ú Ñ I G A G A L V Á N

SCOUTIA

DIPLOMADO EN CIENCIA DE DATOS



DIEGO ANTONIO ZÚÑIGA GALVÁN

INTELIGENCIA ARTIFICIAL APLICADA A LA
VALORACIÓN DE MERCADO DE FUTBOLISTAS



Índice

1. Introducción	2
2. Planteamiento del problema	2
3. Descripción de los datos	3
3.1. FBref — estadísticas de rendimiento	3
3.2. Transfermarkt — valor de mercado y plantillas	3
3.3. Kaggle EA Sports FC — vencimiento de contrato	4
3.4. Wayback Machine — vencimiento de contrato	4
3.5. Resumen comparativo de las fuentes	4
4. Ingeniería de datos	4
4.1. Consolidación de las fuentes	4
4.2. Cruce e identificación de jugadores entre fuentes	5
4.2.1. Mapeo FBref↔Transfermarkt	5
4.2.2. Corrección de colisiones: el caso "Rodri"	5
4.2.3. Corrección de cesiones: el caso "Endrick"	5
4.3. Tratamiento de valores faltantes	6
4.4. Construcción de variables	7
4.4.1. Relativización por posición	7
4.4.2. Codificación de categóricas	7
5. Análisis exploratorio	7
5.1. Univariado	8
5.1.1. Distribución del valor de mercado	8
5.1.2. Atípicos univariantes	8
5.2. Bivariado	9
5.2.1. Correlación con el objetivo	9
5.2.2. La curva de edad	11
5.3. Multivariado	12
5.3.1. Atípicos multivariantes: el caso "Messi"	12
5.3.2. Proyección PCA	12
6. Modelación no supervisada	13
6.1. Clustering de arquetipos (K-Means)	13
7. Modelación supervisada	15
7.1. Regresión lineal (OLS)	15
7.2. Ridge y Lasso	17
7.3. Random Forest	18
7.4. XGBoost	18
7.5. Comparación final y modelo de producción	19
8. Estrategia de negocio	20
8.1. El producto ScoutIA	20
9. Conclusiones	20
9.1. Sigüientes pasos	21

1. Introducción

Este documento analiza información deportiva y de mercado de futbolistas profesionales de las cinco grandes ligas europeas —Premier League, La Liga, Serie A, Bundesliga y Ligue 1— con la finalidad de generar valor a través de la construcción de un modelo que prediga el valor de mercado de un jugador a partir de su rendimiento, y de una aplicación, **ScoutIA**, que sirva ese modelo a un usuario final. Se cruzan cuatro fuentes independientes: FBref.com (estadísticas de rendimiento por temporada), Transfermarkt.com (valor de mercado, posición, altura y fecha de nacimiento), el conjunto de datos público de Kaggle "*EA Sports FC 24 complete player dataset*" y capturas archivadas de Transfermarkt vía Wayback Machine (estas dos últimas para completar el vencimiento de contrato de cada jugador). El periodo cubierto son cinco temporadas, de 2021-2022 a 2025-2026.

Las razones de este estudio buscan ayudar a impulsar la toma de decisiones en el mercado de fichajes de fútbol profesional basadas en un criterio analítico y fundamentadas en los datos, haciendo uso del método científico para lograrlo. El tema de investigación es relevante porque, a pesar de mover miles de millones de euros cada temporada, buena parte de la valoración de un futbolista sigue apoyándose en el juicio cualitativo de ojeadores, agentes y directores deportivos —el propio valor de mercado publicado por Transfermarkt es, en sí mismo, resultado del consenso de una comunidad de colaboradores, no de un cálculo estadístico auditable. El objetivo principal de este proyecto es ampliar el campo de la Inteligencia Artificial dentro de ese ecosistema, para auxiliar y no reemplazar a los profesionales del scouting, permitiéndoles contrastar su criterio con una estimación objetiva, trazable y basada en datos de rendimiento.

2. Planteamiento del problema

El mercado de fichajes de fútbol ha tenido un progreso desigual en la adopción de análisis de datos: los clubes con más recursos ya usan modelos estadísticos de forma intensiva en el reclutamiento, pero no existe una herramienta pública, transparente y auditable que permita a cualquier interesado —un aficionado, un periodista, un club modesto— contrastar el valor de mercado publicado de un jugador contra una estimación basada exclusivamente en su rendimiento deportivo medible.

Los objetivos que se plantean en este análisis buscan dar una solución bajo los siguientes puntos:

- Construir un modelo que prediga el valor de mercado en euros de un futbolista de las cinco grandes ligas a partir de sus estadísticas de rendimiento (minutos, goles, asistencias, tiros, tarjetas, contexto de equipo), comparando distintas familias de modelos de regresión para elegir la más adecuada.
- Identificar qué variables de rendimiento explican mejor el valor de mercado observado, y documentar de forma trazable los problemas de calidad de datos encontrados al cruzar fuentes independientes.
- Servir ese modelo en una aplicación web (ScoutIA) que muestre, para cada jugador, una banda de valor, sus percentiles respecto a jugadores de su misma posición y temporada, y un arquetipo de estilo de juego.

El desarrollo del producto se rige por tres reglas no negociables, fijadas antes de escribir la primera línea de código de modelado: el valor de mercado se presenta siempre como una **banda** (valor bajo / medio / alto), nunca como una cifra puntual, reconociendo la incertidumbre del modelo; nunca se usa lenguaje de "comprar/vender" —los casos donde el modelo difiere fuertemente del precio de mercado se presentan como "casos a revisión manual"—; y el componente de lenguaje natural (LLM) nunca calcula un número, solo redacta en prosa lo que ya calcularon los modelos estadísticos.

3. Descripción de los datos

El proyecto cruza cuatro fuentes independientes, cada una aportando una pieza de información que ninguna fuente individual tiene completa: rendimiento deportivo (FBref), valor de mercado y datos biográficos (Transfermarkt), y vencimiento de contrato (Kaggle y Wayback Machine, combinadas porque ninguna de las dos cubre por sí sola las cinco temporadas). Cada fila del dataset final representa una combinación jugador-temporada.

3.1. FBref — estadísticas de rendimiento

FBref.com publica, para las "Big 5 European Leagues" combinadas, cuatro tablas de estadísticas por jugador y temporada: `stats` (estándar: minutos, goles, asistencias, tarjetas), `shooting` (tiros y tiros a puerta), `misc` (faltas, duelos, recuperaciones) y `playingtime` (minutos por partido, por titularidad, por suplencia). La extracción se hizo con la librería `soccerdata`, que controla un navegador Selenium para cargar cada URL de FBref, guardando el HTML crudo como respaldo y extrayendo la tabla objetivo con BeautifulSoup —incluyendo tablas que FBref oculta dentro de comentarios HTML, una particularidad conocida de su markup.¹

¹ El scraping de FBref usa Selenium (a través de la librería `soccerdata`) porque las tablas se cargan mediante JavaScript; el de Transfermarkt usa peticiones HTTP directas con `requests`, más rápidas al no requerir un navegador completo.

Filas y columnas de las tablas crudas de FBref por temporada

Temporada	stats	shooting	misc	playingtime
2021-2022	3,038	3,038	3,038	3,734
2022-2023	3,004	3,004	3,004	3,668
2023-2024	2,966	2,966	2,966	3,652
2024-2025	2,968	2,968	2,968	3,648
2025-2026	2,952	2,952	2,952	3,677
Columnas	26	20	22	26

La tabla `playingtime` siempre trae más filas que las otras tres porque incluye jugadores con apariciones muy marginales que FBref no reporta en las demás tablas; esto se vuelve relevante al unificar las fuentes (sección 4.1), porque el cruce entre tablas usa `stats` como base.

3.2. Transfermarkt — valor de mercado y plantillas

Transfermarkt.com aporta el valor de mercado (`valor_eur`), la posición detallada, la altura y la fecha de nacimiento —variables que FBref no tiene—. La extracción se hizo en dos fases: primero se listaron los clubes participantes de cada liga y temporada desde la tabla de la liga (484 clubes-temporada guardados en `clubes.csv`), y después se descargó, para cada club-temporada, el HTML crudo de su plantilla (484 páginas, sin parsear en el momento de la descarga, para poder reprocesarlas sin volver a scrapear). El parseo posterior extrajo, por jugador: nombre, dorsal, posición, nacimiento, nacionalidad, altura, pie hábil, fecha de fichaje y valor de mercado, dando como resultado **19,014 filas por 14 columnas** (5.7% de `valor_eur` nulo en crudo). Tras deduplicar por jugador y temporada, quedan **18,002 filas únicas**.



3.3. Kaggle EA Sports FC — vencimiento de contrato

El conjunto *"EA Sports FC 24 complete player dataset"* (usuario `stefanoleone992` en Kaggle, descargado con la API oficial) trae una fotografía anual del videojuego con `fifa_version` 15 a 24. Se usan las versiones 22, 23 y 24, correspondientes a las temporadas 2021-2022, 2022-2023 y 2023-2024 —no existe un dataset equivalente para FC25/FC26, así que no cubre las dos temporadas más recientes—. El cruce con FBref se hace por la llave (inicial del primer nombre, apellido) dentro de (liga, temporada), validada contra el año de nacimiento: 97.7% de los matches coinciden exacto; el resto se anula por probable colisión de apellido.

3.4. Wayback Machine — vencimiento de contrato

Como Kaggle no cubre 2024-2025 ni 2025-2026, esas dos temporadas se completan con capturas archivadas de Transfermarkt vía Wayback Machine, buscando para cada jugador la captura más cercana a la mitad de cada temporada y leyendo el campo "Contrato hasta" de su ficha. De **5,192** pares jugador-temporada consultados, **2,951 (56.8%)** tuvieron un contrato parseable; el resto son ventanas sin ninguna captura archivada o casos donde el propio Transfermarkt no tenía el dato en ese momento. Se descargaron 3,102 páginas HTML archivadas.

3.5. Resumen comparativo de las fuentes

Las cuatro fuentes de datos del proyecto

Fuente	Qué aporta	Volumen crudo	Cobertura temporal
FBref	Rendimiento deportivo	20 archivos, ~3,000-3,700 filas c/u	2021-22 a 2025-26
Transfermarkt	Valor de mercado, posición, altura	19,014 × 14	2021-22 a 2025-26
Kaggle EA Sports FC	Vencimiento de contrato	10,766 filas (Big-5)	2021-22 a 2023-24
Wayback Machine	Vencimiento de contrato	2,951 de 5,192 parseados	2024-25 y 2025-26

4. Ingeniería de datos

Trabajar con cuatro fuentes independientes requiere del apoyo de herramientas adecuadas para llevar a cabo tareas de limpieza, cruce e ingeniería de variables. Todo el proyecto se desarrolla en Python, apoyado principalmente en `pandas`, `BeautifulSoup`, `scikit-learn` y `xgboost`.

4.1. Consolidación de las fuentes

Para cada temporada, las cuatro tablas de FBref se unen usando `stats` como base, incorporando solo las columnas nuevas de `shooting`, `misc` y `playingtime` sobre la llave compuesta jugador-club-competición-año de nacimiento; las cinco temporadas se apilan en un único marco de datos. Del lado de Transfermarkt, las 19,014 filas parseadas se deduplican a 18,002 y se enriquecen con el nombre de club y liga desde `clubes.csv`.

El cruce entre ambas fuentes se hace en tres pasos, cada uno mejorando la cobertura del anterior: primero por un mapeo público de nombres FBref↔Transfermarkt (78.55% de cobertura), después con un mecanismo de respaldo por nombre y año de nacimiento para los casos que el mapeo no cubre (97.83%), y finalmente

incorporando el valor de mercado por jugador y temporada (96.37%). El vencimiento de contrato de Kaggle y Wayback Machine se agrega en un último paso, con una cobertura combinada de 56.7%, variando entre 51.7% (2021-22) y 63.8% (2023-24) según la temporada.

El resultado de esta primera consolidación es **13,953 filas por 70 columnas**, correspondientes a **5,481 jugadores únicos** en las cinco ligas y cinco temporadas del proyecto. Este dataset no ha recibido ningún tratamiento de calidad todavía: es el punto de partida tanto del análisis exploratorio (Capítulo 5) como de la limpieza descrita en el resto de este capítulo.

4.2. Cruce e identificación de jugadores entre fuentes

4.2.1. Mapeo FBref↔Transfermarkt

Como control de calidad del cruce, se comparó el club de FBref (`Squad`, específico de cada temporada) contra el club de Transfermarkt (`club`) tras normalizar el texto: la coincidencia exacta era baja (12.5%) por diferencias de nomenclatura ("Reims" vs. "Stade Reims", "Inter" vs. "Inter Milan"). Con una heurística que quita prefijos genéricos de club ("fc", "cf", "real", "athletic", "deportivo"...) la coincidencia sube a 56.0%; el resto de la discrepancia no es un error, sino que el campo `club` de Transfermarkt es una instantánea del club más reciente del jugador, no un histórico por temporada. Esta columna de coincidencia, llamada `club_coincide`, resultó clave para detectar y corregir los dos problemas descritos a continuación.

4.2.2. Corrección de colisiones: el caso "Rodri"

Durante la etapa de modelado (Capítulo 7), al revisar los residuos de un modelo de árboles, las predicciones para el jugador **"Rodri"** eran inconsistentes entre filas que, según el dataset, tenían el mismo valor de mercado. La causa resultó ser que el cruce por nombre normalizado puede pegar, bajo el mismo identificador de Transfermarkt, las estadísticas de *dos personas reales distintas* que comparten nombre — una colisión de identidad, no una simple fila duplicada—. El alcance medido fue de 735 grupos jugador-temporada con más de un club de FBref para el mismo identificador (1,473 filas, ~10.6% del dataset de esa etapa).

La corrección usa la columna `club_coincide`: de esos 735 grupos, 603 tienen exactamente una fila cuyo club coincide con el de Transfermarkt de esa temporada, así que se conserva esa fila como la correcta; en 74 grupos ninguna fila coincide, y al no existir forma confiable de saber cuál es la persona correcta, se descarta el grupo completo. Queda, no obstante, un caso residual sin resolver: cuando la fila equivocada también coincide por casualidad con su propio club de Transfermarkt, la regla falla. Se confirmó concretamente para dos jugadores, Marc Guéhi y Antoine Semenyo, cuya temporada 2025-2026 muestra de forma espuria "Manchester City" en vez de su club real (Crystal Palace y Bournemouth, respectivamente) —queda documentado como limitación conocida (sección 9.1).

4.2.3. Corrección de cesiones: el caso "Endrick"

Un segundo problema, relacionado con el anterior pero distinto, se detectó probando la aplicación en vivo: la ficha del jugador **Endrick** mostraba 12 minutos y 0 goles para la temporada 2025-2026, cuando en realidad estuvo toda esa temporada cedido en el Olympique Lyon (16 partidos, 1,215 minutos, 5 goles, 7 asistencias), confirmado tanto en los datos de FBref como en la insignia "Returned after loan spell with Olympique Lyon" de la propia plantilla de Transfermarkt.

Cuando un jugador está cedido, FBref genera legítimamente dos filas para la misma temporada —la misma persona real, no una colisión—, pero la regla `club_coincide` (creada para el problema anterior) siempre conserva la fila que coincide con el club de Transfermarkt, que durante una cesión activa siempre muestra al club dueño de la ficha, nunca al club receptor. Esto descartaba sistemáticamente la fila de la cesión, a veces la temporada sustantiva completa del jugador. De los 735 grupos ambiguos totales, solo 120 tenían alguna insignia de cesión en Transfermarkt, y solo 58 tenían evidencia que hiciera coincidir positivamente el nombre de un club con uno de los `Squad` de FBref —23 de esos 58 casos corresponden a la temporada 2025-2026, en vivo en la aplicación—.

La corrección final aplica una regla de dos niveles: si hay evidencia de cesión positivamente verificada para un jugador-temporada, se prioriza sobre `club_coincide` y se conserva la fila del club donde jugó de verdad; si no, se mantiene la regla original. Tras aplicar el fix, Endrick pasó a mostrar 1,215 minutos y 5 goles en el Lyon, y el valor predicho por el modelo saltó de 2.3 a 21 millones de euros, mucho más cercano a la valoración de 40 millones de la propia Transfermarkt. El desglose final de los 735 grupos ambiguos queda así: 603 resueltos por `club_coincide`, 58 por evidencia de cesión, 74 descartados por falta de evidencia confiable —en total 812 filas descartadas de 13,835—.

4.3. Tratamiento de valores faltantes

El diagnóstico de valores faltantes mostró un patrón no aleatorio, agrupado por causas estructurales distintas:

Valores faltantes por columna (sobre 13,953 filas)

Columna	% faltante	Causa
<code>contrato_vence</code>	43.26%	Cobertura parcial de Kaggle/Wayback
<code>Standard_G/SoT</code>	30.03%	División entre 0 (sin tiros a puerta)
<code>Standard_G/Sh</code> , <code>Standard_SoT%</code>	18.15%	División entre 0 (sin tiros)
<code>Subs_Mn/Sub</code>	14.05%	0 suplencias
<code>Starts_Mn/Start</code>	13.32%	0 titularidades
<code>pid_fb</code> , <code>anio_nac</code>	5.00%	Jugador no encontrado en el cruce
<code>valor_eur</code>	0.85%	Sin valoración pública todavía
<code>altura_m</code>	0.44%	No reportado en Transfermarkt

Cada grupo recibió un tratamiento distinto, con una columna indicadora para no perder la señal de "el dato faltaba": los ratios de tiro y los minutos por aparición se imputaron en cero (son ceros estructurales, no información perdida); las métricas de éxito de equipo se imputaron con la mediana por liga y temporada; la altura, con la mediana por posición; los campos de auditoría del cruce se dejaron sin imputar y nunca se usan como variable de entrada al modelo; y el objetivo (`valor_eur`) nunca se imputa —esas 118 filas, correspondientes a jugadores muy jóvenes (edad media 19.8 años) con pocos minutos, se excluyen del subconjunto de modelado—.

Un hallazgo relevante fue que el faltante de `contrato_vence` tampoco es aleatorio: los jugadores sin ese dato juegan sistemáticamente menos minutos (mediana 892 frente a 1,256) y son ligeramente más jóvenes. La explicación es de cobertura, no de fuga de información: Kaggle solo incluye jugadores con carta en el videojuego, y Wayback archiva con más frecuencia las fichas de mayor perfil.

4.4. Construcción de variables

4.4.1. Relativización por posición

Las variables de producción ofensiva (goles, asistencias, tiros) y de involucramiento defensivo (entradas, intercepciones) significan cosas muy distintas según la posición: cinco goles es excepcional para un defensa central pero mediocre para un delantero. Por eso se reemplazó el escalado global de estas variables por un escalado robusto² ajustado dentro de cada posición, de forma que cada jugador se compara contra sus pares de posición y no contra todo el dataset —una decisión correcta para el modelo de valor, pero que resultó contraproducente para el clustering de arquetipos, como se retoma en el Capítulo 6.

² El escalado robusto (`RobustScaler`) centra cada variable en su mediana y la divide entre su rango intercuartílico, en vez de la media y la desviación estándar —es menos sensible a valores extremos, relevante para un dataset donde los valores extremos son información real (Capítulo 5).

4.4.2. Codificación de categóricas

Se eliminaron identificadores sin significado futbolístico, columnas de auditoría del cruce, duplicados exactos entre tablas de FBref y variables derivadas por combinación lineal de otras ya conservadas (por ejemplo, goles más asistencias, cuando ambas ya se conservan por separado). También se eliminó `n_metodos_atipico` —una columna calculada en el EDA usando el propio valor de mercado como entrada de un detector de atípicos, cuyo uso como variable de modelo habría filtrado el objetivo hacia las features—. La nacionalidad (134 categorías) se descartó por alta cardinalidad sin justificación futbolística clara; posición y competición (13 y 5 categorías) se codificaron con variables dummy.

El equipo (`Squad`, 130 categorías) se trató de forma distinta: un one-hot completo generaría más de cien columnas casi siempre dispersas, y agrupar en un top-N perdería la señal individual de clubes medianos con efecto propio sobre el valor de mercado. Se evaluaron codificación por etiqueta, por frecuencia y por objetivo (*target encoding*), optando por esta última porque captura directamente la señal de que los clubes grandes inflan el valor de sus jugadores, sin la explosión dimensional del one-hot. Como el target encoding usa la variable objetivo, se ajusta únicamente sobre el conjunto de entrenamiento, después de separar train y test (Capítulo 7), para no filtrar información del conjunto de prueba.³ Tras esta limpieza, el dataset final de variables queda en **13,023 filas por 65 columnas**.

³ El *target encoding* reemplaza cada categoría por una estimación regularizada (con *shrinkage* hacia la media global según la frecuencia de la categoría) de la media del objetivo para esa categoría, con validación cruzada interna para que la codificación de cada fila no use el objetivo de esa misma fila.


5. Análisis exploratorio

El análisis exploratorio de datos tiene como objetivo extraer la mayor cantidad de información, conocimiento y patrones del dataset consolidado antes de modelar el fenómeno en cuestión. Se toman tres enfoques: análisis univariado (variable por variable), bivariado (pares de variables) y multivariado (múltiples variables simultáneamente), siempre sobre el subconjunto de 13,835 filas con valor de mercado conocido.


5.1. Univariado

5.1.1. Distribución del valor de mercado

El valor de mercado (`valor_eur`) está fuertemente sesgado a la derecha: unos pocos jugadores de élite valen decenas o cientos de millones de euros frente a una mayoría por debajo de los 10 millones. El logaritmo en base 10 acerca la distribución a la simetría, por lo que se usa $\log_{10}(\text{valor_eur})$ como variable objetivo de trabajo en el resto del proyecto.




La misma asimetría se repite en la mayoría de las variables de conteo del rendimiento deportivo (goles, asistencias, tiros): la mayoría de los jugadores acumulan valores bajos y una minoría, valores muy altos.




5.1.2. Atípicos univariantes

Se compararon tres métodos de detección de atípicos univariantes sobre nueve variables clave: rango intercuartílico (IQR, con un umbral de 1.5 veces el rango), z -score clásico (umbral 3) y z -score modificado, basado en la desviación absoluta mediana⁴ (umbral 3.5).

⁴ El z -score modificado reemplaza la media y la desviación estándar por la mediana y la desviación absoluta mediana (MAD), lo que lo hace más robusto ante distribuciones sesgadas.




El método IQR resultó el más "agresivo" en variables de conteo muy asimétricas (goles, tiros, valor de mercado), porque su umbral se calcula sobre cuartiles que, en distribuciones sesgadas, quedan muy próximos entre sí. Esto ya sugería que buena parte de lo que el IQR llama "atípico" en estas variables es simplemente la cola derecha natural del rendimiento y del mercado —jugadores estrella—, no errores de captura, hipótesis que se confirma en el análisis multivariante de la sección 5.3.




5.2. Bivariado


5.2.1. Correlación con el objetivo

Se calculó la matriz de correlación de Pearson entre las variables numéricas del dataset y $\log_{10}(\text{valor_eur})$.



El valor de mercado difiere también de forma sistemática por liga y por posición: Premier League y La Liga muestran las medianas más altas, y delanteros y extremos superan de forma consistente a defensas centrales y porteros.






5.2.2. La curva de edad

La relación entre edad y valor de mercado no es lineal. Se ajustó una curva LOWESS⁵ de $\log_{10}(\text{valor de mercado})$ contra la edad:

⁵ LOWESS (*Locally Weighted Scatterplot Smoothing*) es una técnica de suavizado no paramétrico que ajusta regresiones locales sobre ventanas del eje X, útil para visualizar relaciones no lineales sin asumir una forma funcional concreta.



El valor aumenta con la juventud y la proyección, alcanza su punto máximo alrededor de los 23-27 años, y decae de forma sostenida a partir de ahí —la clásica "curva de edad" del mercado de fichajes—. Esta curva no es uniforme dentro del tramo joven: el mercado paga una prima de potencial muy alta a un grupo pequeño de jóvenes de élite (el caso extremo del dataset es un jugador de 17 años valorado en 200 millones de euros, el más valioso de todo el proyecto), mientras que la gran mayoría de los jugadores jóvenes sin producción demostrada todavía no tiene valoración pública en absoluto. Esta mezcla de "algunos jóvenes valen muchísimo, la mayoría vale poco" resultó ser precisamente lo que más le cuesta capturar a un modelo lineal, como se retoma en la sección 7.1.

5.3. Multivariado

5.3.1. Atípicos multivariantes: el caso "Messi"

Se aplicaron cuatro métodos multivariantes de detección de atípicos sobre nueve variables estandarizadas (edad, altura, minutos, goles, asistencias, tiros, tarjetas, rendimiento de equipo, valor de mercado), cada uno con una contaminación esperada del 2%: *Isolation Forest*, *Local Outlier Factor*, *Elliptic Envelope*⁶ y distancia de Mahalanobis clásica.⁷ Los cuatro coincidieron casi exactamente en cuántas observaciones marcar: 277, 277, 277 y 276 de 13,835.

⁶ *Isolation Forest*, *Local Outlier Factor* y *Elliptic Envelope* son tres métodos de detección de atípicos multivariante: el primero aísla observaciones mediante particiones aleatorias del espacio, el segundo compara la densidad local de cada punto contra la de sus vecinos, y el tercero ajusta una elipse de covarianza robusta y marca lo que queda fuera de ella.

⁷ La distancia de Mahalanobis mide qué tan lejos está una observación del centro de la distribución, teniendo en cuenta la correlación entre variables (a diferencia de la distancia euclidiana, que las trata como independientes).


Jugadores marcados por los cuatro métodos simultáneamente (muestra)

Jugador	Club	Temporada	Edad	Valor (M€)
Lionel Messi	PSG	2021-2022	34	50
Robert Lewandowski	Bayern Munich	2021-2022	32	45
Mohamed Salah	Liverpool	2024-2025	32	50
Neymar	PSG	2022-2023	30	60
Harry Kane	Bayern Munich	2023-2024	30	100
Kevin De Bruyne	Manchester City	2022-2023	31	70
Lamine Yamal	Barcelona	2024-2025	17	200
Kylian Mbappé	PSG	2021-2022	22	160

Los casos en los que coinciden los cuatro métodos son, sin excepción, algunos de los mejores futbolistas del mundo en esa temporada. Son atípicos reales y valiosos, no errores de datos: eliminarlos habría significado eliminar precisamente la señal que un modelo de valoración necesita aprender para el extremo superior del mercado. Esta conclusión motivó la decisión de tratamiento: no se eliminó ninguna observación del dataset; en su lugar se aplicó transformación logarítmica al objetivo y a las variables de conteo más asimétricas, y escalado robusto de cara al modelado.

5.3.2. Proyección PCA

Como verificación visual, se proyectó el espacio de nueve variables estandarizadas a dos componentes principales, coloreando cada observación según cuántos de los cuatro métodos la marcan como atípica.



Los jugadores etiquetados se ubican consistentemente en el extremo del espacio proyectado —literalmente los mejores futbolistas del mundo en esa temporada—, confirmando visualmente la lectura anterior.

6. Modelación no supervisada


A diferencia del aprendizaje supervisado, en el no supervisado no se le otorga al algoritmo ninguna etiqueta: su función es la agrupación. Sobre el mismo pipeline de datos del modelo de valor se construyó, como trabajo adicional, un modelo de arquetipos de estilo de juego.

6.1. Clustering de arquetipos (K-Means)

Se ajustó un K-Means con $k=5$ sobre ocho variables ya escaladas (edad, altura, minutos, tres variables ofensivas, tarjetas amarillas y rendimiento de equipo). Antes de fijar esta decisión se puso a prueba con tres preguntas.

¿Es $k=5$ un buen número de clusters? Se corrió K-Means para k entre 2 y 10, midiendo inercia (método del codo) y el coeficiente de silueta⁸ para cada uno.


⁸ El coeficiente de silueta mide, para cada punto, qué tan similar es a su propio cluster frente a los demás clusters (rango -1 a 1 , más alto es mejor); Davies-Bouldin mide la razón entre dispersión interna y separación entre clusters (más bajo es mejor).



El silhouette óptimo del barrido es $k=2$ (0.310), pero no hay ninguna alternativa claramente superior en el rango de 3 a 9 (silhouette entre 0.145 y 0.181); se mantiene $k=5$ por ser un balance pragmático entre granularidad interpretable y calidad de separación.

¿Variables por posición o en escala global? Las variables ofensivas del modelo de valor están relativizadas por posición (sección 4.4.1) —correcto para predecir valor de mercado, pero contraproducente para encontrar arquetipos de estilo de juego, porque aplana la diferencia real entre un delantero goleador y un defensa que mete algunos goles inusuales para su posición. Probado empíricamente: con las variables relativizadas por posición ningún cluster superaba el 30% de concentración en una sola posición; en escala global aparece un cluster 57% delanteros centro, capturando mucho mejor un arquetipo real de "delantero goleador" (silhouette 0.177 frente a 0.170 del punto de partida).

¿Es K-Means el algoritmo correcto? Se comparó contra *Gaussian Mixture* y *Agglomerative Clustering* sobre el mismo conjunto de variables ganador: K-Means obtuvo el mejor silhouette (0.170) frente a Agglomerative (0.150), mientras que Gaussian Mixture dio un resultado degenerado (silhouette negativo).



Perfil final de los cinco arquetipos (corrida de producción)

Cluster	n	Edad	Minutos	Goles	Etiqueta
0	3,803	23.7	482	0.25	Joven de plantilla modesta, poca participación
1	4,328	27.0	1,944	1.09	Titular recurrente, perfil de contención



Cluster	n	Edad	Minutos	Goles	Etiqueta
2	499	26.2	2,395	13.66	Estrella ofensiva de máximo volumen
3	1,872	25.6	1,969	4.98	Titular ofensivo de buen nivel
4	2,521	23.8	589	0.39	Rotación joven en clubes de alto rendimiento

7. Modelación supervisada

El objetivo es predecir $\log_{10}(\text{valor_eur})$ a partir de las variables construidas en el Capítulo 4. El conjunto se dividió 80/20 en entrenamiento y prueba, separando por jugador (no por fila), para que las distintas temporadas de un mismo jugador no queden repartidas entre ambos conjuntos: 10,352 filas de 4,331 jugadores en entrenamiento, 2,670 filas de 1,083 jugadores en prueba, sin jugadores compartidos entre ambos.

7.1. Regresión lineal (OLS)


Se entrena primero una regresión lineal ordinaria sobre 60 variables, como punto de partida para medir cuánta señal capturan y dónde falla el modelo más simple posible.

Regresión lineal — métricas


	R ²	RMSE (log10)	MAE (€)	MAPE
Entrenamiento	0.727	0.327	4,484,221	79.0%
Prueba	0.731	0.326	4,825,014	78.0%


Las variables de mayor impacto estandarizado⁹ sobre $\log_{\text{valor_eur}}$ son el porcentaje de minutos jugados, el *target encoding* del equipo, los minutos totales y la edad.

⁹ El impacto estandarizado de una variable se calcula como su coeficiente multiplicado por su desviación estándar, y representa el cambio esperado en la variable objetivo ante un incremento de una desviación estándar en esa variable, manteniendo las demás constantes.



El análisis de los residuos mostró un patrón claro: los jugadores más **sobreestimados** por el modelo son casi todos futbolistas muy jóvenes, de 15 a 20 años, de clubes de prestigio con pocos minutos —el modelo lineal les atribuye demasiado valor por combinar juventud y club grande, sin suficiente evidencia todavía de rendimiento real, el mismo fenómeno anticipado en la sección 5.2.2—.





Se probó una hipótesis alternativa: ¿es el prestigio del club, capturado por el *target encoding*, la causa de este sesgo? Se reentrenaron los cinco modelos del capítulo sin esa variable, y el desempeño empeoró en los cinco sin excepción (por ejemplo, XGBoost pasó de $R^2=0.831$ a $R^2=0.803$). La variable carga señal real y sustancial, así que se conserva, y el sesgo con jóvenes de clubes grandes queda documentado como limitación conocida del modelo lineal (sección 9.1).

7.2. Ridge y Lasso

El análisis de coeficientes mostró el síntoma típico de multicolinealidad: el bloque de variables de tiempo de juego tenía signos contradictorios entre sí. Se probaron Ridge (penalización L2, estabiliza coeficientes correlacionados) y Lasso (penalización L1, puede llevar coeficientes exactamente a cero),¹⁰ ambos con el parámetro de regularización elegido por validación cruzada.

¹⁰ Ridge y Lasso agregan, respectivamente, una penalización proporcional a la suma de los coeficientes al cuadrado (L2) o al valor absoluto de los coeficientes (L1) a la función de pérdida de la regresión, reduciendo el sobreajuste; a diferencia de Ridge, Lasso puede llevar coeficientes exactamente a cero, actuando como un mecanismo de selección de variables.

Ridge y Lasso — métricas de prueba

Modelo	R^2	RMSE (log10)	MAE (€)	MAPE
Ridge	0.731	0.326	4,831,470	77.9%
Lasso	0.731	0.326	4,837,111	77.7%

Lasso lleva a cero 3 de 60 coeficientes (porcentaje de goles fuera de juego, altura y minutos totales —esta última interesante, porque otras dos variables del mismo bloque de tiempo de juego ya capturaban esa señal—). Los tres modelos lineales llegan al mismo techo de desempeño y sus residuos están casi perfectamente correlacionados entre sí, confirmando que la multicolinealidad no era el problema real: la limitación es la incapacidad estructural de un modelo lineal de representar relaciones no lineales como el sesgo de juventud descrito arriba.


7.3. Random Forest

Un modelo de árboles no necesita variables escaladas ni asume linealidad, por lo que puede capturar interacciones y no linealidades sin que se le indiquen explícitamente. El modelo base, sin ajustar, queda sobreajustado (R^2 de entrenamiento 0.975 frente a 0.811 en prueba); tras una búsqueda de hiperparámetros por validación cruzada, el mejor modelo obtiene:

Random Forest ajustado — métricas

	R^2	RMSE (log10)	MAE (€)	MAPE
Entrenamiento	0.962	0.123	1,825,928	21.5%
Prueba	0.812	0.272	4,198,608	57.3%

Top 20 variables — Random Forest




7.4. XGBoost

A diferencia de Random Forest, XGBoost construye los árboles de forma secuencial, corrigiendo en cada paso el error de los anteriores. Tras una búsqueda de hiperparámetros equivalente, el mejor modelo obtiene:

XGBoost ajustado — métricas

	R^2	RMSE (log10)	MAE (€)	MAPE
Entrenamiento	0.911	0.187	2,707,623	35.3%
Prueba	0.831	0.258	3,810,318	53.2%



7.5. Comparación final y modelo de producción

Comparación final de los cinco modelos (conjunto de prueba)

Modelo	R ²	RMSE (log10)	MAE (€)	MAPE
Regresión lineal (OLS)	0.731	0.326	4,825,014	78.0%
Ridge	0.731	0.326	4,831,470	77.9%
Lasso	0.731	0.326	4,837,111	77.7%
Random Forest	0.812	0.272	4,198,608	57.3%
XGBoost	0.831	0.258	3,810,318	53.2%

Los tres modelos lineales convergen a un mismo techo ($R^2 \approx 0.73$); los modelos de árbol dan un salto claro en desempeño puro, con XGBoost como el mejor de los cinco.

Sin embargo, el modelo elegido para servir en producción no es XGBoost sino **Lasso** —una decisión deliberada de interpretabilidad, no un descuido—. Los coeficientes de un modelo lineal permiten calcular la contribución de cada variable a una predicción de forma exacta y aditiva (contribución = coeficiente por valor estandarizado, sin aproximación), mientras que explicar una predicción individual de un ensemble de árboles requeriría una técnica aproximada como SHAP.¹¹ Esto está más alineado con el criterio de usar métodos estadísticos clásicos para explicar el modelo, y evita introducir una capa de aproximación en un producto donde la trazabilidad de cada predicción es un requisito de diseño (Capítulo 2). El modelo de producción se reentrena sobre el 100% de los datos (no solo el 80% de entrenamiento), y las métricas de prueba de este capítulo quedan documentadas como la estimación honesta de su generalización.

¹¹ SHAP (*SHapley Additive exPlanations*) es una técnica de explicabilidad basada en teoría de juegos que estima la contribución de cada variable a una predicción individual de un modelo de caja negra, mediante una aproximación —no un cálculo exacto como el de un modelo lineal—.

8. Estrategia de negocio

El objetivo de negocio es ofrecer, tanto a aficionados y periodistas como a profesionales del scouting con recursos limitados, una segunda opinión objetiva y trazable sobre el valor de un futbolista, sin pretender sustituir el criterio experto. Para ello se desarrolló **ScoutIA**, una aplicación web con backend FastAPI y frontend Angular, construida sobre los artefactos del modelo de valor (Capítulo 7) y del clustering de arquetipos (Capítulo 6).

8.1. El producto ScoutIA

La ficha de cada jugador muestra sus estadísticas, la banda de valor predicha por el modelo, sus percentiles frente a jugadores de su misma posición y temporada (calculados sobre ocho estadísticas), y su arquetipo de estilo de juego. Un comparador reutiliza los tres modelos ya servidos —percentiles, Lasso y K-Means— para contrastar a dos jugadores lado a lado, sin reentrenar nada. Una vista de "oportunidades" filtra a los jugadores vigentes cuya banda de valor predicha supera su valor de mercado en Transfermarkt, ordenados por brecha absoluta, presentados siempre como "casos a revisión manual" y nunca con lenguaje de comprar o vender, en línea con las reglas de producto fijadas desde el planteamiento del problema (Capítulo 2).

Un componente de lenguaje natural redacta en prosa las diferencias ya calculadas entre dos jugadores comparados: nunca recibe estadísticas crudas ni calcula ningún número, solo verbaliza el JSON que ya produjeron los modelos estadísticos. Como prototipo adicional, no integrado al producto final, se exploró un componente de análisis de noticias que combina la API de ESPN con un modelo de lenguaje para clasificar artículos deportivos por categoría y sentimiento, vinculándolos a jugadores mediante las etiquetas estructuradas que la propia ESPN ya incluye —evitando que el modelo de lenguaje tenga que adivinar nombres de jugadores en texto libre—.

9. Conclusiones

Como prueba de concepto se acepta la viabilidad de la solución planteada en el Capítulo 2: se construyó un modelo capaz de explicar el 73.1% de la varianza del logaritmo del valor de mercado con un modelo lineal interpretable, y hasta el 83.1% con un modelo de árboles, a partir únicamente de estadísticas de rendimiento deportivo y contexto de equipo —sin usar, deliberadamente, ninguna fuente de opinión o reputación distinta al propio rendimiento en el campo—. El proceso completo, desde el scraping de cuatro fuentes independientes hasta un producto servido, permitió además identificar y corregir dos problemas reales de calidad de datos (los casos "Rodri" y "Endrick") que habrían pasado inadvertidos sin una revisión sistemática de los residuos del modelo, y confirmar, mediante detección de atípicos multivariante, que los futbolistas de mayor valor del dataset (Messi, Mbappé, Lamine Yamal, entre otros) son señal real del extremo superior del mercado y no errores de captura.

El proceso que debería repetirse cada temporada, a medida que FBref y Transfermarkt publican datos nuevos, es el siguiente:

1. Descargar las tablas de FBref y las plantillas de Transfermarkt de la temporada nueva.
2. Aplicar el mismo pipeline de cruce y limpieza, incluyendo la regla de dos niveles para colisiones y cesiones (sección 4.2).

3. Validar el cruce con las mismas comprobaciones de consistencia (coincidencia de club, coincidencia de posición entre fuentes).
4. Reentrenar el modelo de producción (Lasso) sobre el 100% de los datos acumulados.
5. Recalcular percentiles, arquetipos y artefactos servidos por la aplicación.

Cabe recalcar que la solución no es perfecta en ninguno de los pasos: el sesgo hacia jugadores jóvenes de clubes grandes persiste incluso en el modelo de producción, la cobertura de vencimiento de contrato es parcial, y existe al menos un caso residual de colisión de identidad sin resolver. Aceptar que todo modelo trae consigo un margen de error deja cabida a las oportunidades de mejora del siguiente apartado.

9.1. Siguiendo pasos

A lo largo del desarrollo se identificaron oportunidades de mejora concretas, no exploradas todavía:

- Investigar si el caso residual de colisión de identidad (Guéhi, Semenyo) responde al mismo mecanismo que el bug "Rodri" o a un artefacto distinto en el orden de deduplicación de Transfermarkt, y diseñar una regla que lo atrape sin reintroducir falsos positivos.
- Explorar una interacción explícita entre el *target encoding* del equipo y la experiencia o los minutos acumulados del jugador, como vía para atacar el sesgo de juventud sin perder la señal legítima de prestigio de club.
- Evaluar si una explicación por SHAP sobre XGBoost, con su mejor desempeño predictivo, sería aceptable como alternativa a la interpretación exacta de Lasso, para una futura fase del proyecto.
- Ampliar la cobertura de vencimiento de contrato más allá de Kaggle y Wayback Machine, quizá con una fuente que no dependa de la disponibilidad de capturas archivadas.
- Completar la integración del prototipo de análisis de noticias (sección 8.1) como una señal adicional, no sustitutiva, de contexto reciente sobre cada jugador.